Kalp Hastalığı Tahmininde Farklı Topluluk Öğrenmesi Algoritmalarının Başarım Analizi

Şeyda Aytemür[1]
2220656048

[1]Bilgisayar Mühendisliği Bölümü, Çorlu Mühendislik Fakültesi, Namık Kemal Üniversitesi, Tekirdağ, Türkiye

---

Öz (Abstract)

Bu çalışmanın amacı, klinik veriler kullanılarak bireylerin kalp hastalığı risk durumlarını (Var/Yok) belirlemek için modern topluluk öğrenmesi (Ensemble Learning) yöntemlerinin etkinliğini incelemektir. Çalışmada, 270 örneklem ve 13 klinik öznitelikten oluşan "Heart Disease Prediction" veri seti kullanılmıştır. Sınıflandırma işlemi için Python ortamında Random Forest (Bagging), AdaBoost ve XGBoost (Boosting) algoritmaları geliştirilmiş ve test edilmiştir. Modellerin başarısını ölçmek amacıyla doğruluk (accuracy), kesinlik (precision), duyarlılık (recall) ve F1-skoru gibi metriklerin yanı sıra karışıklık matrisleri (confusion matrix) kullanılmıştır. Deneysel sonuçlar, gradyan tabanlı optimizasyon kullanan XGBoost algoritmasının, kalp hastalığı teşhisinde diğer topluluk yöntemlerine göre daha yüksek genelleme kapasitesi ve başarım sergilediğini ortaya koymuştur.

Anahtar Kelimeler: Makine Öğrenmesi, Kalp Hastalığı Tahmini, Topluluk Öğrenmesi (Ensemble Learning), XGBoost, Random Forest, AdaBoost.

---

1. Giriş (Introduction)

Kardiyovasküler hastalıklar, dünya çapında en yüksek ölüm oranına sahip sağlık sorunlarının başında gelmektedir. Bu hastalıkların erken teşhisi, tedavi süreçlerinin planlanması ve hasta sağkalım oranlarının artırılması açısından kritik bir öneme sahiptir. Geleneksel tanı yöntemlerinin yanı sıra, makine öğrenmesi algoritmaları büyük veri setleri içerisindeki gizli örüntüleri analiz ederek klinik karar destek sistemlerine güçlü bir zemin hazırlamaktadır.
Literatürde tekli sınıflandırma modelleri (Karar Ağaçları, SVM vb.) sıklıkla kullanılsa da, bu modellerin aşırı öğrenme (overfitting) ve düşük genelleme yeteneği gibi kısıtları bulunmaktadır. Bu kısıtları aşmak amacıyla geliştirilen "Topluluk Öğrenmesi" (Ensemble Learning) yöntemleri, birden fazla zayıf öğreniciyi bir araya getirerek daha dayanıklı ve yüksek performanslı modeller oluşturulmasını sağlar.
Bu çalışma kapsamında, tıbbi verilerin sınıflandırılmasında topluluk öğrenmesinin sağladığı avantajlar incelenmiş; bagging ve boosting tabanlı üç temel algoritmanın (Random Forest, AdaBoost, XGBoost) kalp hastalığı tahmini üzerindeki performansları deneysel olarak karşılaştırılmıştır.

3. Materyal ve Yöntem (Materials and Methods)

Bu bölümde, çalışmada kullanılan veri setinin karakteristik özellikleri, veri ön işleme aşamaları ve sınıflandırma amacıyla seçilen topluluk öğrenmesi algoritmalarının teknik detayları ele alınmıştır.

3.1. Veri Seti (Dataset)

Deneylerde kullanılan "Heart Disease Prediction" veri seti, toplam 270 hastaya ait klinik kayıtları içermektedir. Veri setinde her bir örneklem 13 adet sayısal ve kategorik öznitelik (feature) ile temsil edilmektedir. Hedef değişken (target), kalp hastalığının varlığını (Presence) veya yokluğunu (Absence) ifade eden iki sınıflı (binary) bir yapıdadır.

Heart Disease (target)	(Hastalık Var/Yok)	**FBS**	Açlık kan şekeri > 120 mg/dl (1 = Evet, 0 = Hayır)
Age	Hastanın yaşı	**EKG results**	Dinlenme elektrokardiyografi sonuçları
Sex	1 = Erkek, 0 = Kadın	**Max HR**	Ulaşılan maksimum kalp hızı
Thallium	Talyum stres testi sonucu	**Exercise angina**	Egzersize bağlı anjin
Chest pain type	Göğüs ağrısı tipi	**ST depression**	Dinlenmeye göre egzersizle indüklenen ST depresyonu
BP	Dinlenme kan basıncı (mm Hg)	**Slope of ST**	Pik egzersiz ST segmentinin eğimi
Cholesterol	Serum kolesterol düzeyi (mg/dl)	**Number of vessels fluro**	Floroskopi ile renklendirilmiş ana damar sayısı

Tablo 1. Verisetindeki Öznitelikler

3.2. Veri Ön İşleme (Data Preprocessing)

Modellerin eğitim sürecine geçilmeden önce verilerin algoritmalar tarafından doğru yorumlanabilmesi amacıyla kapsamlı bir ön işleme süreci yürütülmüştür. Bu aşamada izlenen adımlar şunlardır:

- Etiket Kodlama (Label Encoding): Veri setindeki hedef değişken olan "Heart Disease" (Presence/Absence), LabelEncoder kullanılarak sayısal formata dönüştürülmüştür. Bu işlem sonucunda "Presence" sınıfı 1, "Absence" sınıfı 0 değeri ile temsil edilmiştir.
- Veri Bölümleme (Train-Test Split): Modelin daha önce görmediği veriler üzerindeki performansını test edebilmek amacıyla veri seti; %80 eğitim ve %20 test seti olmak üzere ikiye ayrılmıştır. Deneylerin tekrarlanabilirliğini sağlamak adına random_state=42 parametresi kullanılmıştır.
- Özellik Ölçeklendirme (Feature Scaling): Veri setindeki özniteliklerin (Yaş, Kolesterol, Kan Basıncı vb.) farklı sayısal aralıklara sahip olması, modelin bazı değişkenlere yanlış ağırlık vermesine neden olabilir. Bu riski ortadan kaldırmak için StandardScaler kullanılarak veriler standartlaştırılmıştır.
- Sütun Koruma: Ölçeklendirme işlemi sonrası NumPy dizisine dönüşen veriler, raporun ilerleyen kısımlarındaki öznitelik analizi ve görselleştirme adımları için tekrar Pandas DataFrame formatına getirilerek orijinal sütun isimleri korunmuştur.

3.3. Uygulanan Algoritmalar

Ödev kapsamında aşağıdaki üç farklı yaklaşım kullanılmıştır:

1. Random Forest (Bagging): Karar ağaçlarını paralel olarak eğitir ve sonuçların ortalamasını/çoğunluğunu alır.
2. AdaBoost (Boosting): Yanlış sınıflandırılan örneklerin ağırlıklarını arttırarak ardışık şekilde öğrenen bir Boosting yöntemidir.
3. XGBoost (Extreme Gradient Boosting): Gradyan artırma yöntemini yüksek performans ve düzenlileştirme (regularization) ile birleştiren modern bir algoritmadır.

4. Deneysel Tasarım (Experimental Design)

Bu çalışmada kullanılan modeller, Python'ın scikit-learn ve xgboost kütüphaneleri kullanılarak oluşturulmuştur. Deneylerin tutarlılığı ve tekrarlanabilirliği için tüm modellerde random_state=42 parametresi sabit tutulmuştur.

- 4.1. Random Forest (Bagging): n_estimators=100 parametresi ile 100 adet karar ağacı paralel olarak eğitilmiştir. Her bir ağaç, verinin farklı alt kümeleri üzerinde eğitilerek varyansın düşürülmesi hedeflenmiştir.
- 4.2. AdaBoost (Boosting): Yine n_estimators=100 yapılandırması tercih edilerek, zayıf öğrenicilerin (weak learners) ardışık olarak hatalara odaklanması sağlanmıştır.
- 4.3. XGBoost (Modern Boosting): eval_metric='logloss' parametresi ile gradyan artırma performansı optimize edilmiştir. Model, regülarizasyon desteği sayesinde aşırı öğrenmeye karşı daha dayanıklı bir yapı sergilemiştir.

5. Performans Metrikleri ve Karşılaştırma

	Accuracy	Precision	Recall	F-1 Score
Random Forest	**0,7593**	**0,7562**	**0,7593**	**0,7552**
AdaBoost	**0,8519**	**0,8513**	**0,8519**	**0,8503**
XGBoost	**0,8148**	**0,8134**	**0,8148**	**0,8129**

Tablo 2. Detaylı Performans Metrikleri

Tablo 2'deki metrikler incelendiğinde, AdaBoost algoritmasının tüm performans göstergelerinde (Doğruluk, Hassasiyet, Duyarlılık ve F1-Skoru) diğer iki modeli geride bıraktığı açıkça görülmektedir. AdaBoost %85,19 doğruluk oranı ile en kararlı sonuçları verirken, onu %81,48 ile XGBoost takip etmektedir.
Kalp hastalığı gibi tıbbi teşhis problemlerinde sadece genel doğruluk değil, aynı zamanda Recall (Duyarlılık) değeri kritik öneme sahiptir. AdaBoost'un %0,85'lik Recall değeri, gerçekte hasta olan kişilerin doğru tespit edilme oranının yüksek olduğunu kanıtlamaktadır. Random Forest ise %75,93 ile bu veri setinde en düşük performansı sergilemiş, bu da Boosting yöntemlerinin (AdaBoost ve XGBoost) bu spesifik problemde Bagging yöntemine (Random Forest) göre daha etkili olduğunu göstermiştir.

5. Karmaşıklık Matrisi (Confusion Matrix) Analizi

		Predicted Class	
		Positive	**Negative**
Actual Class	**Positive**	TP	FN
	Negative	FP	TN

Tablo 3. Confusion Matrix

- Doğru Pozitif (True Positive - TP): Modelin, gerçekte kalp hastalığı olan bir hastayı doğru bir şekilde "Kalp Hastalığı Var" (1) olarak tahmin etmesidir.
- Doğru Negatif (True Negative - TN): Modelin, gerçekte sağlıklı olan bir bireyi doğru bir şekilde "Sağlıklı / Hastalık Yok" (0) olarak tahmin etmesidir.
- Yanlış Pozitif (False Positive - FP): Gerçekte sağlıklı olan bir bireyin, model tarafından hatalı bir şekilde "Kalp Hastalığı Var" olarak tahmin edilmesidir.
- Yanlış Negatif (False Negative - FN): Gerçekte kalp hastalığı olan bir hastanın, model tarafından gözden kaçırılarak hatalı bir şekilde "Sağlıklı" olarak tahmin edilmesidir.

$$\text{Accuracy}=\frac{TP+TN}{TP+FP+FN+TN} \quad (1)$$

$$\text{Specificity}=\frac{TN}{FP+TN} \quad (2)$$

$$\text{Sensitivity}=\frac{TP}{TP+FN} \quad (3)$$

Random Forest

Confusion Matrix

Gerçek Değer	0	1
0	28	5
1	8	13

Tahmin Edilen

Tablo 4

AdaBoost

Confusion Matrix

Gerçek Değer	0	1
0	30	3
1	5	16

Tahmin Edilen

Tablo 5

XGBoost

Confusion Matrix

Gerçek Değer	0	1
0	29	4
1	6	15

Tahmin Edilen

Tablo 6

Karmaşıklık matrisleri incelendiğinde, modellerin hata dağılımları şu şekildedir:

- AdaBoost (En İyi Performans): 54 test örneği içinde 30 sağlıklı bireyi ve 16 hasta bireyi tam doğru tespit etmiştir. Sadece 5 yanlış negatif (FN) hata yapmıştır; yani hasta olduğu halde "sağlıklı" dediği kişi sayısı en düşük olan modeldir. Tıbbi teşhislerde bu hata türünün (hastayı gözden kaçırmak) hayati önem taşıdığı düşünüldüğünde, AdaBoost güvenilir bir performans ortaya koymuştur.
- XGBoost: 29 sağlıklı ve 15 hasta bireyi doğru sınıflandırmıştır. Yanlış negatif sayısı (6) AdaBoost'a yakındır, ancak sağlıklı bireyleri hasta gibi gösterme oranı (4 FP) biraz daha yüksektir.
- Random Forest: Diğer modellerle kıyaslandığında en yüksek yanlış negatif (8 FN) oranına sahiptir. 21 hasta bireyden 8'ini sağlıklı olarak sınıflandırmış, yani hastaların yaklaşık %38'ini tespit edememiştir. Bu durum, Bagging yönteminin bu veri setindeki küçük ancak kritik detayları yakalamakta Boosting yöntemleri kadar hassas olmadığını göstermektedir.

Özetle modellerin tamamı "Sağlıklı" (0) sınıfını tahmin etmede daha başarılıyken, "Hasta" (1) sınıfının tespiti konusunda Boosting algoritmaları özellikle AdaBoost çok daha kesin sonuçlar üretmiştir.

6. Genel Değerlendirme ve Sonuç

Bu çalışmada, kalp hastalığı tahmini üzerine kurulu bir veri seti üzerinde üç farklı topluluk öğrenmesi (Ensemble Learning) algoritması olan Random Forest (Bagging), AdaBoost ve XGBoost (Boosting) başarıyla uygulanmış ve performansları kıyaslanmıştır.

Yapılan testler ve analizler sonucunda ulaşılan temel çıkarımlar şunlardır:

- Boosting Yöntemlerinin Üstünlüğü: AdaBoost (%85,19) ve XGBoost (%81,48) algoritmaları, Random Forest'a (%75,93) göre belirgin bir üstünlük sergilemiştir. Bu durum, veri seti yapısındaki karmaşık örüntülerin, hata odaklı öğrenen ardışık (Boosting) yöntemler tarafından daha iyi kavrandığını göstermektedir.
- Kritik Kazanç (Hata Analizi): Tıbbi teşhislerde hayati önem taşıyan "yanlış negatif" (hastayı teşhis edememe) oranı, AdaBoost modelinde minimum seviyeye indirilmiştir. AdaBoost hem genel doğrulukta hem de hassas sınıflandırmada en güvenilir model olarak öne çıkmıştır.
- Model Kararlılığı: Kalp hastalığı gibi 13 farklı özelliğin bulunduğu bu tip veri setlerinde, topluluk öğrenmesi yöntemlerinin klasik tekli algoritmalara göre çok daha sağlam (robust) ve güvenilir tahminler ürettiği doğrulanmıştır.

Sonuç olarak; kalp hastalığı riski taşıyan bireylerin erken teşhisinde AdaBoost gibi yüksek hassasiyetli topluluk öğrenmesi modellerinin kullanılması, klinik karar verme süreçlerini destekleyecek güçlü bir potansiyele sahiptir.